

소비기한 날짜 추출 실험 현재 SOTA 검증 보고서

Kaggle 영역 라벨 기반 YOLOv8n Expiry Detector와 Full-Image PP-OCrv6의 Dual-Branch 결합 및 공간 정밀 Selector 검증 결과

최고 실측 정확도 (Final EM)

80.61 %

ITDA 내부 Validation (459장)

후보 존재 시 선택 정확도

94.63 %

Train-fit Spatial Selector

날짜 후보 검출률 (Recall)

85.19 %

Dual Branch 결합 후 도달

단독 Full OCR 대비 상승폭

+8.93 %p

71.68% → 80.61% 대폭 개선

검증 평가 대상: ITDA Validation Split 459장 전수 평가 (Test Split 459장은 완전 잠금 및 미사용)

평가 환경 및 시점: Colab T4 Fresh Execution (2026-09-14 실측 데이터 기준)

성능 공표 지침: 외부 학술 SOTA가 아닌 "ITDA 내부 validation 기준 최고 실측 결과"로 표현 규정

본 보고서는 ITDA OCR Challenge(식품 유통·소비기한 자동 추출) 과제에서 개발된 인공지능 파이프라인의 최고 성능 구조와 전체 실험 분석 결과를 다룹니다. 복잡한 수식 대신 "어떻게 글자를 찾고, 어떻게 진짜 소비기한을 고르는가"를 명확한 실측 수치와 함께 정리했습니다.

최고 성능 달성 구조

Full OCR + YOLO Dual-Branch Union

전체 사진을 넓게 보는 시야(Branch A)와 소비기한 영역만 정밀하게 확대하는 돋보기(Branch B)를 합친 이중화 앙상블 구조

검증된 최고 실측 성능

Final Exact Match 80.61%

내부 validation(459장) 기준 기존 베이스라인(71.68%) 대비 **+8.93%p** 향상. (* 학술 논문이나 외부 세계 SOTA가 아닌 ITDA 내부 실측치)

현재 가장 큰 병목

인식 단계 후보 누락 (Recall 85.19%)

일단 후보 목록에 정답 날짜가 들어오면 **94.63%** 확률로 정확히 골라냅니다. 즉, 잘못 고르는 것보다 *처음에 글씨를 못 읽어오는 것*이 주 원인입니다.

차기 집중 개선 영역

Dual Crop & Line Reconstruction

글자가 잘리거나 위아래로 나뉜 날짜("2026."과 "05.12")를 재조합하는 텍스트 결합 로직 및 4-core CPU 최적화에 집중합니다.

핵심 인사이트

"YOLO 날짜 검출기 단독으로는 문맥(제조일자 구별 등)을 잃어버려 성능이 67.76%로 떨어집니다. 반면 전체 OCR과 결합했을 때 비로소 **80.61%**라는 내부 최고 기록이 완성되었습니다. 이는 YOLO를 '대체 모델'이 아니라 '보조 탐색기'로 썼을 때 진정한 시너지가 난다는 것을 실증합니다."

실제 제품에 인쇄된 소비기한은 폰트가 규격화되어 있지 않고, 비닐의 구김, 조명 반사, 제조일자나 바코드와의 혼재 등 현실적인 방해 요소가 극심합니다. 본 대회는 현실 배포 환경을 상정하여 다음과 같은 엄격한 3대 제약 조건을 요구합니다.

1. CPU-Only (4-Core 타겟)

제출 및 최종 평가는 GPU가 없는 순수 4-core CPU 서버에서 수행됩니다. 모델 크기와 연산량이 작아야 하며, 메모리 누수가 없어야 합니다.

2. 완전한 오프라인 추론

추론 시 인터넷 연결, 외부 API 호출, 원격 대규모 언어모델(GPT-4, Gemini 등) 연동이 원천 금지됩니다. 로컬 경량 모델만 구동 가능합니다.

3. Test Split 철저 잠금

데이터 오염(Data Leakage)을 방지하기 위해 459장의 Test Split은 모델 튜닝에 절대 사용하지 않았으며, 오직 고정된 Validation(459장)으로만 검증했습니다.

데이터 출처와 중복 여부를 수학적 해시(CRC32/SHA-256) 검증을 통해 철저히 감사했습니다. Kaggle 데이터셋과 ITDA 대회 드라이브의 관계를 규명한 것이 성능 도약의 열쇠가 되었습니다.

구분	이미지 수	설명 및 무결성 검증
ITDA 원본 이미지	3,352장	대회 제공 원본 상품 이미지 풀
Gemini-filtered 라벨	3,063장	품질 검증을 통과한 유효 정답셋
- Train Split	2,145장	모델 학습 및 Selector 가중치 피팅
- Validation Split	459장	모든 벤치마크 실측 기준 (N=459)
- Test Split	459장	최종 제출 평가용 완전 비공개 잠금
Split 간 파일명 중복	0장 (Disjoint)	물리적 분리 및 데이터 누출 0% 확인



Kaggle 데이터셋의 진정한 효과 분석

Kaggle의 *Korean Product Expiration Date Dataset*을 전수 조사한 결과, 대회 드라이브의 3,352장과 **완전히 동일한 사진**(3,343장 파일명 동일 + 9장 카카오톡 파일명 변경, 바이트 CRC32 일치)임이 확인되었습니다.

결정적 발견:

Kaggle 데이터셋을 활용해 성능이 오른 이유는 "새로운 이미지가 추가되어서"가 아니라, 기존 사진 속 **날짜 위치(date/due box) 좌표 라벨**이 추가로 확보되어 정밀한 YOLO Detector를 학습시킬 수 있었기 때문입니다.

본 파이프라인은 문맥을 유지하는 전체 OCR(Branch A)과 소비기한 영역을 정밀 확대하는 YOLO Detector(Branch B)를 병렬로 운영한 후, 지능형 앙상블 Selector를 통해 최종 날짜를 확정합니다.

원본 상품 이미지

해상도 유지 입력
A4/식품 포장재 사진

Input

**Branch A: Full-Image OCR**

- PP-OCRv5 mobile det + v6 medium rec
- 전체 문맥 보존: "제조", "유통기한" 위치 파악

Context

Branch B: YOLO Expiry Crop

- YOLOv8n Expiry Binary (Kaggle 학습)
- 960px 패치 Crop → v6 rec 판독

Recall Boost

**후보 결합 & Train-Fit Selector**

1. 후보 병합 & 캘린더 유효성 검증
2. 공간 일치도(IoU) & 키워드 가중치 평가

Ensemble

최종 정규화 (YYYY-MM-DD)

단일 날짜 표준 포맷 변환 완료 (결측: NoNE/None)

Output

 Train-Fit Spatial Selector 가중치(Weights)의 쉬운 해석

복잡한 수식 대신 5가지 상식적 판단 기준을 종합하여 점수를 매깁니다:

- **YOLO 보너스 (+1.5):** "YOLO 날짜 전문 탐색기가 찾아낸 박스 안에 있는 글자인가?"
- **날짜 파서 신뢰도 (+1.5):** "완전한 연-월-일 형태를 갖추었는가?" (부분 날짜 감점)
- **OCR 글자 확신도 (+1.5):** "OCR 판독기가 글자를 흐릿하지 않고 선명하게 읽었는가?"
- **탐지 신뢰도 (+0.5):** "텍스트 검출 박스의 형태가 깨지지 않았는가?"
- **공간 일치도 IoU (+0.5):** "전체 화면 탐색 박스와 YOLO 정밀 박스가 같은 자리를 가리고 있는가?"

아래 수치는 추정이 아닌 동일한 459개 검증 이미지에 대해 직접 수행된 최신 실측 결과입니다. GPU 실측 과 CPU 배포 환경 을 명확히 구분하여 표기했습니다.

파이프라인 모델 구성	구분	Final EM (정확도)	Candidate Recall	Selection Acc (후보존재시)	처리속도 (sec/img)
Full OCR + YOLO Expiry Union (현재 SOTA)	Colab T4	80.61%	85.19%	94.63%	~0.47s
Full-Image Baseline (PP-OCRv5 det + v6 rec)	Colab T4	71.68%	75.60%	94.81%	0.425s (2.3 img/s)
YOLO Expiry Crop 단독 (960px + v6 rec)	Colab T4	67.76%	72.33%	93.67%	0.532s (1.8 img/s)
YOLO Expiry Crop (1280px + v6 rec)	Colab T4	66.23%	71.90%	92.12%	- *
[과거 VESSL 참고] Full-Image Baseline (GPU)	VESSL T4	69.28%	75.38%	91.91%	0.176s (5.6 img/s)
[과거 VESSL 참고] CPU Detector Branch (4-core)	VESSL 4-core	67.76%	72.33%	93.67%	0.863s (1.1 img/s)
[과거 VESSL 참고] CPU Full-Image Baseline (4-core)	VESSL 4-core	69.28%	75.38%	91.91%	4.870s (0.2 img/s)

*1: Union 처리속도는 Branch A 및 Branch B의 순차 결합 추정치입니다. *2: YOLO 1280px(44.37초)은 Warm-Cache 후속 측정이므로 정확도만 수록했습니다. *3: [감사 각주] 과거 multi_architecture_leaderboard의 결과는 180장 공유 캐시 시뮬레이션 및 하드코딩 가산치 문제로 감사 결과 전면 무효화되어 영구 제외되었습니다.

주요 파이프라인 모델 정확도(Final EM) 비교 시각화

검증 데이터셋: ITDA val.csv (N=459)

Full OCR + YOLO Union (SOTA)	80.61%	80.61%
Full-Image Baseline (PP-OCRv6)	71.68%	71.68%
YOLO Expiry Crop 단독 (960px)	67.76%	67.76%
YOLO Expiry Crop 단독 (1280px)	66.23%	66.23%

수많은 시행착오를 거치며 검증된 핵심 가설들의 성공 및 실패 원인을 5대 영역으로 정리했습니다:

실험 영역	적용 기법 및 파라미터	성능 변화 및 실측치	원인 분석 및 최종 판단
글자 인식기 (Recognizer)	PP-OCRv5 mobile vs server vs PP-OCRv6 medium	v5 mobile(34~45%) → server(64~71%) → v6 medium(71.68%)	채택 SVTR 기반 v6 medium이 한글·숫자 혼합 글꼴에서 월등한 인식을 입증.
이미지 전처리 (Preprocessing)	Grayscale 변환 + Contrast 대비 강조 (B35)	EM 71.88% → 56.25% 급락 (-15.63%p)	기각 인위적 명암 조절이 도트 프린터 글자나 잉크 번짐을 손상시켜 OCR 실패 유발.
Detector 해상도 Sweep	960px vs 1280px vs 1536px (conf 0.20)	960px: 22.42 img/s (1.70 GB, 454장 박스 검출) 1280px: 17.90 img/s (3.00 GB, 455장 박스 검출) 1536px: 14.91 img/s (4.30 GB, 454장 박스 검출)	최적화 960px을 기본 1차 경로로 채택. 1280px은 불확실 샘플 fallback으로 사용하며, 메모리만 낭비하는 1536px은 전면 배제.
문자열 제한 Fine-tuning	Date-only CTC 학습 & 숫자 Sanitizer 적용	CTC Exact Match 0% 기록 / End-to-end 성능 55.7% → 51.5% 하락	기각 억지로 숫자만 나오게 강제하면 이미 잘린 텍스트가 복구되지 않고 오인식만 가중됨.
영역 Crop 전략	YOLO 박스 1.25배 확대 Crop vs 1.0배 고정 Margin	1.25배 확대 시 Candidate Recall 84.97% → 70.37% 폭락	최적화 박스를 넓히면 주변 성분표나 바코드가 침범하여 혼란 가중. 원본 박스 (expand=1.0) 유지.

07 심층 병목 분석 (Bottleneck Analysis)

데이터 기반 패인 규명

"왜 100점이 나오지 않는가?"를 분석하기 위해 파이프라인을 후보 생성(Recall)과 후보 선택(Selection) 2단계 퍼널로 분리했습니다.

STEP 1. 이미지 입력

Total

459 장

검증 대상 전체 이미지

STEP 2. 날짜 후보 검출

주요 병목
(85.19%)

391 장 성공

68장 (14.81%) 후보 누락: 글자 미인식/파싱 실패

STEP 3. 최종 날짜 선택

안정적
(94.63%)

370 장 적중

Final EM 80.61%: 후보 존재 시 94.63% 정답 선택

Full Baseline 오답 130건 원인 분석 (오류 내부 비율)

GEN (후보 생성 실패)

61건 (46.92%)

"2025."와 "09."처럼 연월일이 분리되어 날짜로 조립 실패

REC (글자 인식 실패)

50건 (38.46%)

도트 잉크 번짐, 각도 기울어짐 등으로 글자 판독 누락

SEL (선택 오류)

18건 (13.85%)

후보에 정답이 있었으나 제조일/코드를 기반으로 오선택

DET (영역 검출 누락)

1건 (0.77%)

박스 자체를 못 찾은 경우는 1건에 불과해 검출기는 양호

대표 이미지 검증 사례 (Per-Image Evidence)

IMG_000084 (복합 날짜)

성공 (정확 일치)

실제 정답 2026-03-31

추출 후보 2026.03.31 (소비) / 2025.10.01 (제조)

선택 이유 later_expiry_date (더 미래 날짜) & 키워드 가중치

IMG_000100 (특수 형식)

성공 (정확 일치)

실제 정답 2026-02-11

추출 원문 "2026.02.11 (A) Best before"

선택 이유 expiry_keyword (Best before 근접) 가산점 부여

IMG_000050 (토큰 분리)

실패 (GEN 후보 누락)

실제 정답 2025-09-10 (추정)

인식 결과 "2025."와 "09."만 읽고 일자 잘림

오류 분석 2025-09-None 파싱되어 유효 캘린더 탈락

IMG_000057 (저조도/흐림)

실패 (REC 글자 누락)

실제 정답 2026-05-18

인식 결과 숫자 토큰 0개 검출 (Candidate Count: 0)

오류 분석 어두운 포장재 비닐 반사로 글자 인식이 통과 실패

대회 채점 서버는 **순수 4-core CPU 오프라인** 환경입니다. 모델이 아무리 정확해도 CPU 환경에서 런타임 에러가 나거나 1장당 수십 초가 걸리면 실격 처리됩니다. 다음 항목들을 정밀 점검했습니다:

✅ 확인 및 검증 완료된 사항

- **CPU 패키지 호환:** Paddle 3.3.0 CPU wheel 단독 환경에서 정상 import 및 1장 단일 추론 무결성 확인 완료.
- **정확도 재현성:** 최신 80.61% EM은 Validation(459장) 전수 재추론으로 확인된 Fresh 실측치임.
- **과거 4-core VESSL 기준속도:** Detector Branch 단독 0.863초/장 실측 완료.

⚠️ 발견된 중대 이슈 및 해결 조치

CPU oneDNN(MKLDNN) 활성화 시 PIR 충돌 발생:

Paddle 3.3 CPU 런타임에서 `enable\_mkldnn=true` 활성화 시 `ConvertPirAttribute2RuntimeAttribute` 치명적 오류가 발생하며 프로세스가 중단됨.

필수 제출 설정:

제출용 CPU 파이프라인에서는 반드시 `enable_mkldnn=false, FLAGS_use_mkldnn=0`으로 강제 비활성화해야 정상 구동됩니다.

솔직하고 투명한 기술적 한계 공지 (4-Core 미측정)

"구글 Colab 무료 런타임은 2 vCPU 환경이므로, **현재 80.61% SOTA Union 파이프라인의 4-core CPU 전체 실행 속도는 아직 측정되지 않았습니다(미측정)**. 2 vCPU Colab에서 MKLDNN을 끈 단일 이미지 테스트는 약 13초가 소요되었으나, 이는 전체 최적화 속도를 대변하지 않습니다. 과거 4-core VESSL 측정값(Full OCR 4.87s + Detector 0.86s = 단순 합산 약 5.73 초/장 상한)을 참고치로 유지하며, 제출 전 4-vCPU 전용 인스턴스에서 1회 완주 측정을 반드시 수행해야 합니다."

선택(Selection)은 이미 94.63%에 도달했으므로, 남은 14.81%의 후보 누락(Recall)을 해결하기 위한 6대 실행 계획에 집중합니다:

1. Dual Crop (Tight + Context)

글자만 바짝 자른 타이트 크롭과 주변 15% 여백을 포함한 컨텍스트 크롭을 동시 생성하여 잘림 방지.

2. Line Reconstruction

위아래 2줄로 나뉜 낱짜("2026." 아래 "09.12")를 공간적 수직 거리를 계산해 한 줄로 이어붙임.

3. 320×64 / 480×64 최적화

낱짜 문자열 종횡비에 맞춰 인식기 입력을 조절하여 도트 폰트 왜곡을 줄이고 연산 속도 가속.

4. Perspective Crop 보정

비스듬히 찍힌 포장재의 각도를 수평으로 자동 보정한 후 전달하는 4-point 투영 변환 적용.

5. Selective Second Pass

1차 960px에서 낱짜 후보가 0개이거나 확신도가 낮을 때만 1280px 정밀 탐색기를 조건부 호출.

6. Date/Due/Code 관계 추론

제조일(date)과 소비기한(due), 배치코드(code)의 기하학적 배치 패턴으로 진짜 기한 특정.